Universidad del Valle – Cali, Colombia
Escuela de Ingeniería de Sistemas y Computación

# Clasificación de imágenes de hojas de caña de azúcar

## Comparación entre perceptrón multicapa y red convolucional

Ervin Caravali Ibarra – 201925648 | Erika García Muñoz – 202259395

28 de marzo de 2026

Repositorio: github.com/ErvinCaraval/Redes-Neuronales-Proyecto-Practico

**Resumen**

**Objetivo.** Comparar el desempeño de un perceptrón multicapa (MLP) y de una red neuronal convolucional profunda basada en EfficientNet-B0 con transferencia de aprendizaje, para la clasificación multiclase de imágenes RGB en diez categorías de enfermedades o estados en follaje de caña de azúcar.

**Metodología.** Se utilizó un conjunto de $N$=8492 imágenes particionado en entrenamiento ($n$=5946, ≈70 %), validación ($n$=1273, ≈15 %) y prueba ($n$=1273, ≈15 %), con semilla aleatoria `SEED = 42`. El MLP recibió vectores aplanados de 128×128×3 píxeles con normalización lineal; la CNN empleó el preprocesado propio de EfficientNet-B0 y aumentación de datos solo en entrenamiento. Ambos modelos se entrenaron en TensorFlow 2.21 / Keras con el optimizador Adam, entropía cruzada categórica y detención anticipada basada en la pérdida de validación.

**Resultados.** El MLP (25,6 M parámetros, ≈91 min de entrenamiento) obtuvo exactitud 0,6520 en prueba. La CNN (165 K parámetros entrenables sobre 4,2 M totales, ≈41 min) alcanzó 0,9159, superando al MLP en ≈0,26 puntos en exactitud, precisión, *recall* y F1 ponderados.

**Conclusiones.** La red convolucional aprovecha la estructura espacial de las imágenes y los pesos preentrenados en ImageNet, confiriéndole una ventaja sistemática sobre el MLP. Quedan abiertas limitaciones por desbalance de clases y la dependencia de un único conjunto de prueba fijo.

# 1. Introducción

La identificación automática de patrones visuales en cultivos es un área activa del aprendizaje automático. En el marco del proyecto de Redes Neuronales de la Universidad del Valle, la primera entrega exige contrastar un MLP con un modelo de aprendizaje profundo, reportar métricas de desempeño y analizar los resultados críticamente.

El problema consiste en clasificar fotografías de hojas de caña de azúcar en diez clases: *Carbon*, *Hoja amarilla*, *Mancha anillo*, *Mancha parda*, *Mosaico*, *Muermo rojo*, *Roya*, *Sanas*, *Secas* y *Tizón bacteriano*. La inclusión de clases de referencia (*Sanas*, *Secas*) reduce el sesgo hacia la predicción exclusiva de enfermedad, pero exige separar categorías visualmente próximas.

Las redes densas sobre píxeles aplanados pueden modelar relaciones complejas, pero exigen muchos parámetros y no reflejan directamente la disposición bidimensional de la imagen [1, 2]. Las redes convolucionales combinan información de parches locales y reutilizan los mismos filtros en distintas zonas, lo que encaja mejor con datos visuales [2, 3].

# 2. Materiales y métodos

## 2.1. Descripción del conjunto de datos

Para este proyecto se construyó un dataset propio a partir de la integración de varios datasets públicos disponibles en internet, entre ellos: Sugarcane Leaf Image Dataset, Sugarcane Disease Classification Dataset, Sugarcane Leaf Disease Dataset, Sugarcane Plant Diseases Dataset, Sugarcane Smut Dataset y Sugarcane Plant Disease Dataset of Assam.

De cada fuente se seleccionaron las imágenes más útiles y se realizó un proceso de depuración, priorizan-

do aquellas con mejor calidad visual. El objetivo fue obtener un conjunto de datos más limpio y consistente para el entrenamiento de los modelos.

El dataset final contiene 8492 imágenes de hojas de caña de azúcar distribuidas en 10 clases. Ocho de estas corresponden a enfermedades comunes del cultivo: roya (1000 imágenes), mancha parda (1000), mancha de anillo (702), hoja amarilla (1000), mosaico (1000), carbón (500), tizón bacteriano (1000) y muermo rojo o pudrición roja (1000). Además, se incluyeron dos clases adicionales: hojas sanas (1000) y hojas secas (290).

Este conjunto de datos presenta algunos retos importantes. Por un lado, existe desbalance entre clases, ya que algunas tienen menos muestras, como carbón y hojas secas. Por otro lado, al provenir de múltiples fuentes, hay variabilidad en iluminación, ángulos, fondos y condiciones de captura.

Estas características hacen que el problema sea más complejo, pero también más representativo de escenarios reales, por lo que deben tenerse en cuenta al momento de analizar los resultados.

## 2.2. Conjunto de datos y partición

El directorio de trabajo contiene tres subconjuntos mutuamente excluyentes: `train`, `val` y `test`, con tamaños $n_{\text{tr}}$=5946, $n_{\text{val}}$=1273 y $n_{\text{te}}$=1273 ($N$=8492):

$$\frac{n_{\text{tr}}}{N} \approx 70\,\%, \quad \frac{n_{\text{val}}}{N} \approx 15\,\%, \quad \frac{n_{\text{te}}}{N} \approx 15\,\%.$$

La fracción mayor ajusta pesos; la validación selecciona hiperparámetros y activa la reducción de tasa de aprendizaje; el conjunto de prueba permanece intacto hasta la evaluación final [1, 2]. Todas las imágenes se redimensionaron a 128×128 píxeles RGB. La carga de datos se realizó con `tf.keras.utils.image_dataset_from_directory` con semilla fija `SEED = 42` para garantizar reproducibilidad.

La clase *Secas* presenta menor soporte ($n_{\text{te}}$=43) que las demás (150 en la mayoría, 105 en *Mancha anillo*, 75 en *Carbon*), lo que refleja la distribución natural del dataset original; esta menor representación incrementa la varianza de las estimaciones de métricas para dicha clase.

## 2.3. Preprocesamiento

Para el MLP se aplicó escalado lineal a $[0, 1]$ mediante una capa `Rescaling` de Keras. Para la CNN se empleó `preprocess_input` de EfficientNet, que centra y normaliza los canales según las estadísticas de ImageNet. Durante el entrenamiento de la CNN se aplicó aumentación geométrica y fotométrica (volteos, rotación hasta ±30°, variación de brillo y zoom leve); validación y prueba se mantuvieron sin aumentación.

## 2.4. Arquitecturas

**MLP.** Red secuencial con entrada aplanada de 128×128×3 valores; ocho capas densas (512, 512, 256, 128, 128, 64, 64, 32 unidades) con activación ReLU, normalización por lotes, *dropout* (0,2 en los primeros cuatro bloques; 0,1 en los restantes) y regularización L2 ($\lambda$=$10^{-4}$). Salida: softmax de 10 unidades. **Total de parámetros: 25,631,338** (todos entrenables).

**CNN.** Se seleccionó EfficientNet-B0 por su favorable relación entre rendimiento y eficiencia computacional respecto a otras arquitecturas de escala similar (MobileNetV2, ResNet-50): con apenas ≈5,3 M de parámetros totales en su configuración estándar, obtiene resultados competitivos en ImageNet gracias a la escalabilidad compuesta (*compound scaling*) que equilibra profundidad, anchura y resolución [3]. Se utilizó con pesos ImageNet congelados y una cabeza clasificadora compuesta por *Global Average Pooling*, capa densa de 128 unidades (ReLU), *dropout* 0,5 y softmax de 10 clases. **Parámetros totales: 4,214,829;** de ellos, **entrenables: 165,258** (cabeza); no entrenables: 4,049,571 (EfficientNet-B0 congelado).

## 2.5. Entrenamiento y evaluación

Ambos modelos se ejecutaron en CPU (TensorFlow 2.21, sin GPU disponible en el entorno) con semilla `SEED = 42` y lote de 32 imágenes.

**MLP:** Adam (tasa inicial $10^{-4}$, penalización de pesos $10^{-4}$); hasta 45 épocas con detención anticipada (*patience* = 10) y *ReduceLROnPlateau* (factor 0,5, *patience* = 3, mínimo $10^{-6}$); se guardó el modelo con menor pérdida de validación. **Tiempo total: ≈91 min** (45 épocas, ≈121 s/época).

**CNN:** Adam con parámetros por defecto de Keras; hasta 50 épocas con detención anticipada (*patience* = 5); la corrida terminó en la época 17. **Tiempo total: ≈41 min** (17 épocas, ≈145 s/época).

En prueba se calcularon exactitud global y, mediante `scikit-learn`, precisión, *recall* y F1 con promedio ponderado (apropiado ante el desbalance de clases).

# 3. Resultados

## 3.1. Métricas globales

La Tabla 1 resume el desempeño en prueba. La CNN supera al MLP en ≈0,26 puntos en cada métrica, pese a entrenar **155 veces menos parámetros** y tardar **la mitad de tiempo**.

**Tabla 1:** Métricas globales en prueba ($n_{\text{te}}$=1273).

| Modelo | Exact. | Prec. | Recall | F1 |
|---|---|---|---|---|
| MLP | 0,652 | 0,663 | 0,652 | 0,653 |
| CNN | 0,916 | 0,921 | 0,916 | 0,917 |

## 3.2. Desglose por clase

Las Tablas 2 y 3 detallan las métricas por clase. Destacan dos clases problemáticas para el MLP: *Roya* obtiene el recall más bajo (0,4000) frente a 0,8800 en la CNN; *Secas*, con menor soporte ($n$=43), alcanza F1 = 0,5195 en el MLP frente a 0,9268 en la CNN.

**Tabla 2:** MLP: métricas por clase en prueba. Parámetros totales: 25,631,338. Tiempo de entrenamiento: ≈91 min (45 épocas).

| Clase | Precisión | Recall | F1 | Soporte |
|---|---|---|---|---|
| Carbon | 0,9114 | 0,9600 | 0,9351 | 75 |
| Hoja amarilla | 0,6934 | 0,6333 | 0,6620 | 150 |
| Mancha anillo | 0,7582 | 0,6571 | 0,7041 | 105 |
| Mancha parda | 0,7500 | 0,7400 | 0,7450 | 150 |
| Mosaico | 0,6107 | 0,6067 | 0,6087 | 150 |
| Muermo rojo | 0,4502 | 0,6933 | 0,5459 | 150 |
| Roya | 0,4839 | 0,4000 | 0,4380 | 150 |
| Sanas | 0,7279 | 0,6600 | 0,6923 | 150 |
| Secas | 0,5882 | 0,4651 | 0,5195 | 43 |
| Tizón bacteriano | 0,7569 | 0,7267 | 0,7415 | 150 |
| macro avg | 0,6731 | 0,6542 | 0,6592 | 1273 |
| weighted avg | 0,6632 | 0,6520 | 0,6531 | 1273 |

**Tabla 3:** CNN (EfficientNet-B0 + cabeza): métricas por clase en prueba. Parámetros entrenables: 165,258 de 4,214,829 totales. Tiempo de entrenamiento: ≈41 min (17 épocas).

| Clase | Precisión | Recall | F1 | Soporte |
|---|---|---|---|---|
| Carbon | 1,0000 | 1,0000 | 1,0000 | 75 |
| Hoja amarilla | 0,9635 | 0,8800 | 0,9199 | 150 |
| Mancha anillo | 1,0000 | 0,9619 | 0,9806 | 105 |
| Mancha parda | 0,9507 | 0,9000 | 0,9247 | 150 |
| Mosaico | 0,9412 | 0,8533 | 0,8951 | 150 |
| Muermo rojo | 0,7784 | 0,9133 | 0,8405 | 150 |
| Roya | 0,8571 | 0,8800 | 0,8684 | 150 |
| Sanas | 0,8727 | 0,9600 | 0,9143 | 150 |
| Secas | 0,9744 | 0,8837 | 0,9268 | 43 |
| Tizón bacteriano | 0,9730 | 0,9600 | 0,9664 | 150 |
| macro avg | 0,9311 | 0,9192 | 0,9237 | 1273 |
| weighted avg | 0,9210 | 0,9159 | 0,9169 | 1273 |

## 3.3. Comparación gráfica en prueba

La Figura 1 compara las cuatro métricas globales; en todas, la CNN supera al MLP con una brecha de ≈0,26. La Figura 2 muestra las matrices de confusión normalizadas: el MLP presenta mayor masa fuera de la diagonal; la CNN concentra los aciertos en ella.

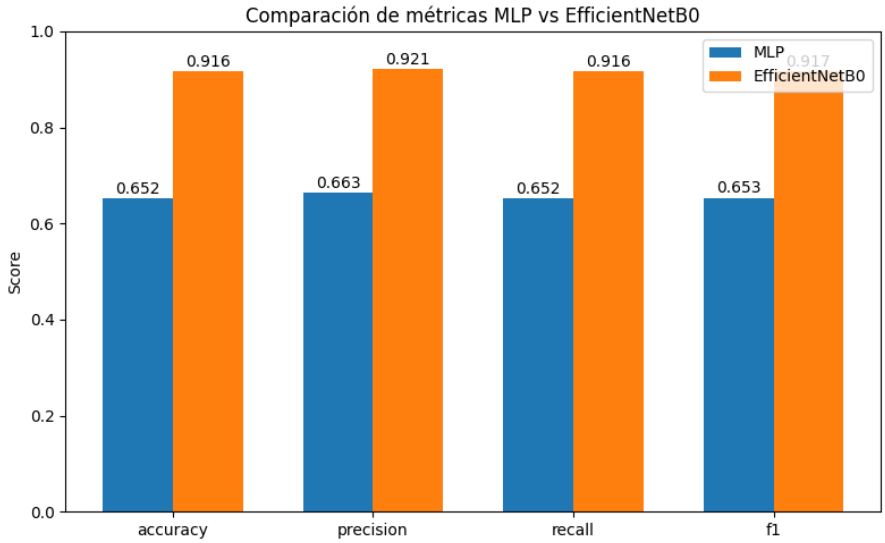


**Figura 1:** Comparación de métricas globales en prueba. La CNN muestra superioridad sistemática sobre el MLP en las cuatro métricas.

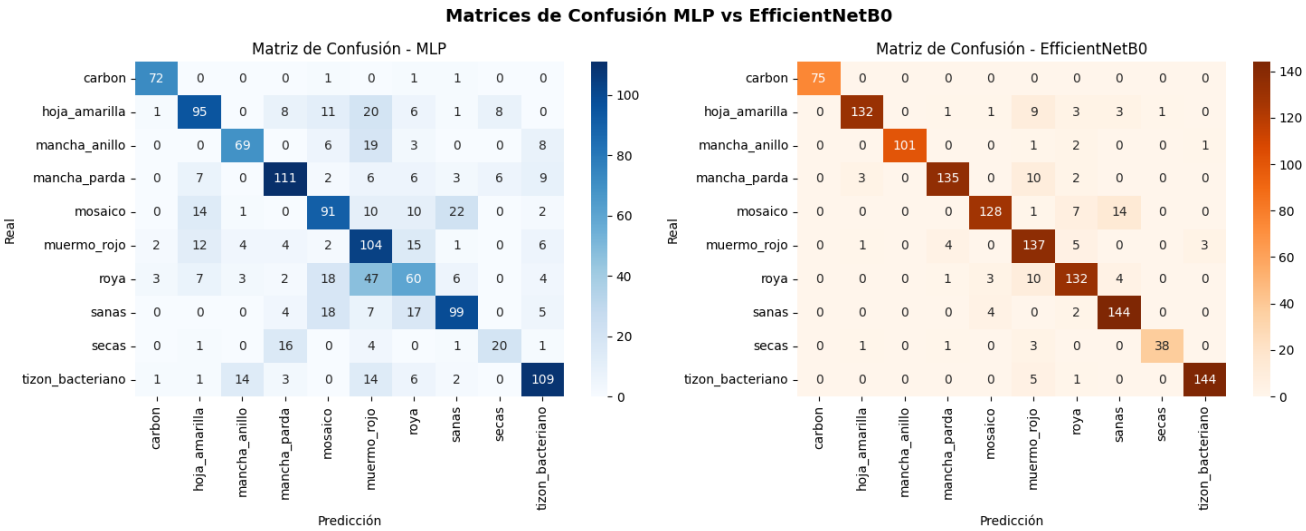


**Figura 2:** Matrices de confusión normalizadas en prueba (filas: clase real; columnas: predicción). Izquierda: MLP. Derecha: CNN (EfficientNet-B0).

## 3.4. Curvas de entrenamiento — MLP

**Fig. 3a.** Los escalones en la tasa de aprendizaje corresponden a intervenciones automáticas de *ReduceLROnPlateau*; no se aprecia divergencia entre entrenamiento y validación.

**Fig. 3b.** La exactitud de entrenamiento y validación avanzan en paralelo hacia la época 45 (0,6480 y 0,6269): el límite es la capacidad de representación, no el sobreajuste.

**Fig. 4a.** Las pérdidas al cierre (1,2548 y 1,2714) confirman la cercanía entre ambos conjuntos.

**Fig. 4b.** La matriz de confusión en validación sirve de referencia de consistencia con la Figura 2.

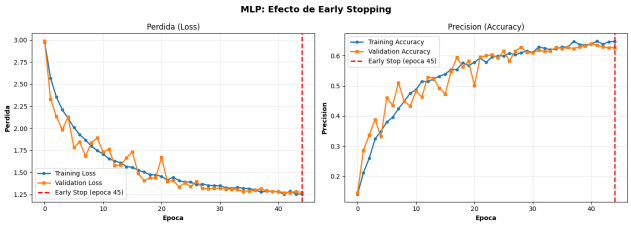


**(a)** MLP: pérdida de validación y tasa de aprendizaje por época.

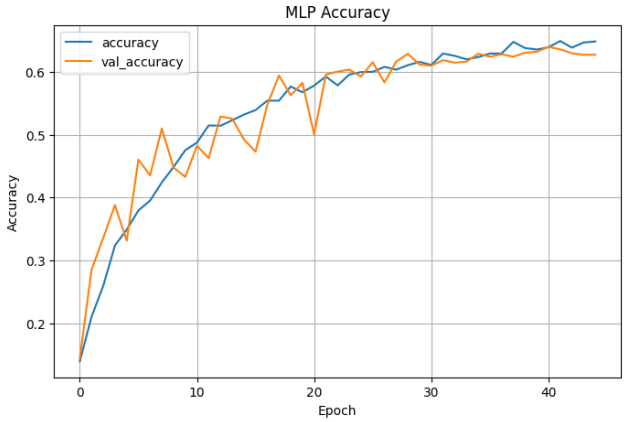


**(b)** MLP: exactitud por época.

**Figura 3:** MLP: curvas de entrenamiento (I). Semilla `SEED = 42`.

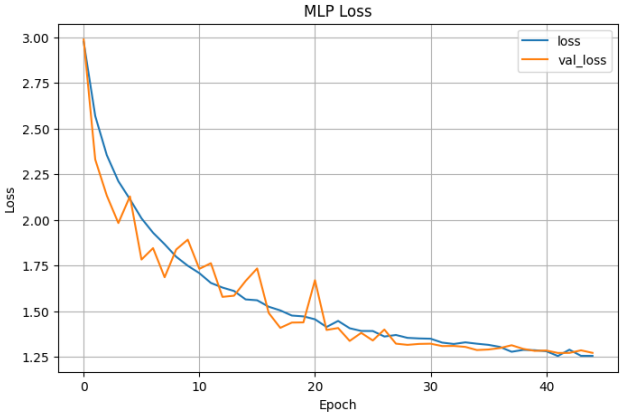


**(a)** MLP: pérdida por época.

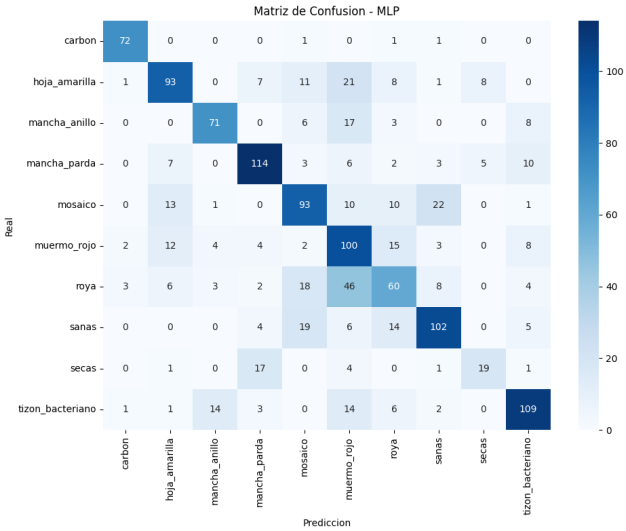


**(b)** MLP: matriz de confusión en validación.

**Figura 4:** MLP: curvas de entrenamiento (II) y confusión en validación.

## 3.5. Curvas de entrenamiento — CNN

**Figs. 5a–5b.** La pérdida cae rápidamente y la exactitud de validación escala hasta ≈0,91–0,92 en solo 17 épocas, evidenciando la ventaja de los pesos preentrenados. La brecha moderada entre pérdidas (0,2536 y 0,3004) indica regularización efectiva.

**Fig. 6.** La matriz de confusión en validación exhibe menor dispersión que la del MLP, coherente con su superioridad en prueba.

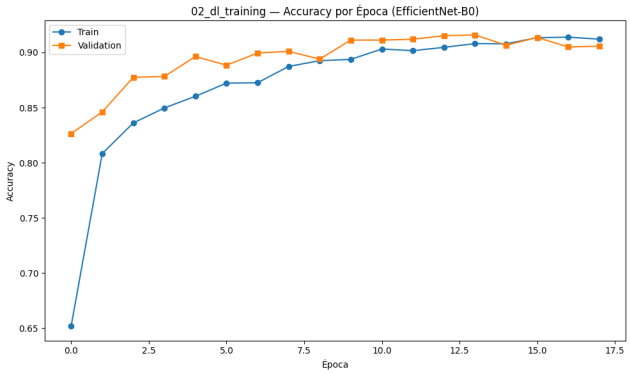


**(a)** CNN: exactitud por época.

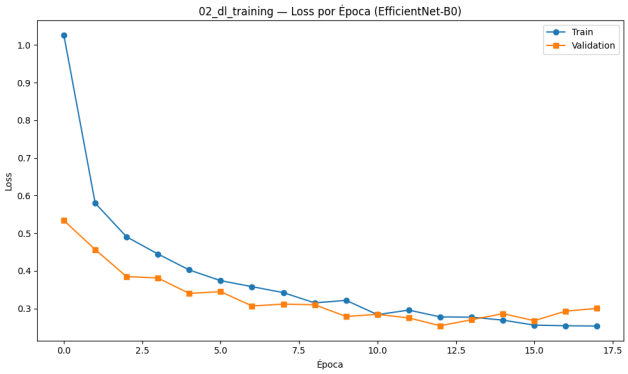


**(b)** CNN: pérdida por época.

**Figura 5:** CNN: curvas de entrenamiento. Convergencia en 17 épocas (≈41 min total en CPU).

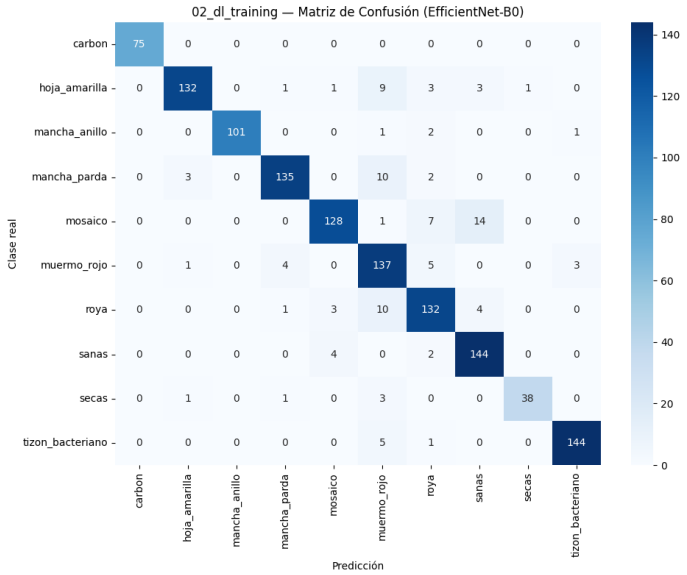


**Figura 6:** CNN: matriz de confusión en el conjunto de validación.

# 4. Discusión

## 4.1. Hipótesis explicativas

**H1 — Estructura espacial.** Los síntomas foliares se reconocen mejor explotando la vecindad entre píxeles. El MLP, al aplanar la imagen en un vector de 128×128×3=49,152 valores, pierde esa estructura y dificulta detectar manchas o texturas bajo pequeñas variaciones de posición o escala [2, 3].

**H2 — Transferencia de aprendizaje y elección de EfficientNet-B0.** EfficientNet-B0 fue seleccionado por su eficiencia computacional: con solo 165 K parámetros entrenables logra aprovechar 4,0 M de parámetros congelados que detectan bordes y texturas útiles en cualquier dominio visual [3]. Frente a ResNet-50 (≈25 M) o VGG-16 (≈138 M), EfficientNet-B0 ofrece un punto de partida más liviano y adecuado para el hardware disponible (CPU, sin GPU). La convergencia en 17 épocas respalda esta elección.

**H3 — Costo de parámetros del MLP.** Con 25,6 M de parámetros, el MLP es 155 veces más grande en parámetros entrenables que la cabeza de la CNN, pero con menor exactitud final. La regularización aplicada (*dropout*, normalización por lotes, L2) mitiga pero no elimina la dificultad de generalizar en un espacio de entrada de alta dimensión con $N$=8492 imágenes [1]. El recall bajo en *Roya* (0,4000) y el F1 reducido en *Secas* (0,5195) encajan con esta lectura.

## 4.2. Interpretación integrada

La brecha no es solo global: la CNN mejora el recall de forma transversal en todas las clases (Tablas 2–3). Las matrices de confusión alinean la evidencia cualitativa con las métricas cuantitativas: el MLP muestra un patrón de errores heterogéneo; la CNN concentra las predicciones en la diagonal.

Cabe señalar que estos resultados no implican validez fitopatológica automática: los modelos aprenden correlaciones estadísticas del conjunto disponible y su generalización a nuevas condiciones de captura requiere validación adicional en campo.

# 5. Conclusiones

Se comparó un MLP (25,6 M parámetros, ≈91 min) con una CNN EfficientNet-B0 (165 K parámetros entrenables, ≈41 min) para clasificar imágenes de follaje de caña de azúcar. La semilla `SEED = 42` y la partición 70/15/15 % garantizan la reproducibilidad y una estimación del error de generalización libre de contaminación por decisiones de ajuste.

Los resultados en prueba favorecen sistemáticamente a la CNN en exactitud, precisión, *recall* y F1 ponderados (≈0,26 puntos de ventaja), con la mitad del tiempo de entrenamiento y una fracción mínima de parámetros entrenables, en concordancia con la literatura sobre aprendizaje profundo para tareas visuales [1, 2, 3].

# Referencias


[1] Bishop CM. Pattern recognition and machine learning [Internet]. New York: Springer; 2006 [cited 2026 Mar 28]. Available from: https://www.microsoft.com/en-us/research/uploads/prod/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf

[2] Goodfellow I, Bengio Y, Courville A. Deep learning [Internet]. Cambridge (MA): MIT Press; 2016 [cited 2026 Mar 28]. Available from: https://www.deeplearningbook.org/

[3] Elgendy M. Deep learning for vision systems. Shelter Island (NY): Manning Publications; 2020.